长篇小说 AI 改编系统：技术架构与实现方案

1. 核心挑战与解决思路

1.1 300 万字长文本处理的核心瓶颈

1.1.1 LLM 上下文窗口限制（通常 4K-128K tokens） 大型语言模型在处理超长文本时面临的根本性约束在于其固定的上下文窗口容量。当前主流商用 LLM 的上下文窗口范围从 4K tokens（约 3000 汉字）到 128K tokens（约 10 万汉字）不等，而 300 万字的中文小说按常规编码折算约为 **450 万-600 万 tokens**，远超任何单一模型的处理能力。这一硬性限制意味着无法将完整小说一次性输入模型进行改编，必须采用分段处理策略。然而，简单的文本切分会导致严重的信息丢失：当模型仅处理第 50 章时，可能已遗忘第 5 章埋下的关键伏笔、第 12 章建立的人物关系，或第 1 章设定的世界观规则。这种”失忆”现象在改编工作中尤为致命，因为剧本创作要求对全书的主题脉络、人物成长弧线和情节呼应关系有全局把握。因此，技术架构必须设计一种**外部记忆机制**，使模型在处理任意文本片段时都能高效检索到相关的背景信息，而非依赖有限的上下文窗口。

1.1.2 长距离依赖与剧情连贯性维护 长篇小说中普遍存在跨越数十章甚至上百章的叙事依赖关系。典型场景包括：第 3 章出现的神秘道具在第 78 章成为扭转战局的关键；配角在第 20 章的随口一提，实则为第 150 章的身份揭露埋下伏笔；主角的性格转变从第 30 章开始酝酿，历经中间 80 章的事件催化，最终在第 110 章完成蜕变。这些长距离依赖构成了小说的叙事张力，但在分段改编过程中极易断裂。若缺乏系统性的追踪机制，改编后的剧本可能出现 **“人物动机突兀”“情节转折生硬”“伏笔无回收”** 等致命缺陷。更复杂的是，电视剧本与电影剧本对连贯性的要求维度不同：电视剧需要每集内部闭环同时保留跨集悬念，电影则要求三幕结构内的严密因果链条。因此，技术方案必须建立显式的情节依赖图谱，支持改编时的主动检索与一致性校验。

1.1.3 人物设定与世界观的一致性保持 人物是叙事的核心载体，其设定的一致性直接决定改编质量。300 万字小说中，主要人物可能经历数百次出场，其外貌特征、性格特质、能力数值、人际关系、目标动机均可能随剧情演进发生变化。人工改编时尚需反复查阅前文史料，AI 改编若仅依赖局部上下文，极易出现 **“人物性格突变”“能力数值矛盾”“关系状态错乱”** 等问题。世界观设定同样复杂：修仙小说的境界体系、科幻小说的技术规则、历史小说的事件时间线，均需在全书中保持严格一致。技术架构需要将这些设定要素结构化抽取，形成可随时调用的”设定数据库”，并在生成过程中强制注入提示，确保输出符合既定规则。

1.1.4 改编过程中的信息丢失与主题漂移风险 从文学小说到影视剧本的转换涉及媒介特性的根本差异：小说可自由进入人物内心进行心理描写，剧本则需通过动作和对白外化情感；小说可铺陈环境氛围，剧本需将描述转化为可视场景；小说的时间节奏由读者控制，剧本必须在固定时长内完成叙事。这些转换规则若仅靠端到端的黑箱生成，极易导致原著精髓的流失——关键主题被稀释、核心冲突被弱化、独特风格被抹平。更危险的是 **“主题漂移”现象**：当模型逐段处理时，可能因局部优化而逐渐偏离全书的核心命题，使改编结果成为情节的堆砌而非意义的表达。因此，技术方案必须在架构层面嵌入”主题锚定”机制，将小说的核心冲突、情感基调、象征系统显式编码，并在每段改编时作为约束条件注入。

1.2 知识图谱增强 LLM 的核心价值

1.2.1 外部化长期记忆，突破上下文限制 知识图谱作为结构化的外部记忆系统，从根本上解决了 LLM 上下文窗口的瓶颈问题。通过将 300 万字小说的关键信息抽取为**实体-关系-属性的三元组网络**，系统可以在常数时间内检索任意人物、事件、地点的完整信息，而无需受限于 tokens 数量。具体而言，当改编第 N 章时，系统可动态查询：该章涉及哪些人物？这些人物的完整背景是什么？当前场景与哪些前序事件存在因果关联？场景地点的设定细节有哪些？这种 **“按需加载”模式**使有效上下文从固定的 128K tokens 扩展到整个知识图谱的规模，实现了”无限上下文”的模拟。根据火山引擎的技术实践，LangChain 的 LLM Graph Builder 工具可自动化完成从文本到图谱的转换，大幅降低工程实现成本。

1.2.2 结构化存储人物、事件、地点等关键实体 知识图谱的本体设计（Ontology）为小说元素提供了统一的语义框架。与纯文本存储相比，结构化表示支持复杂的模式查询，例如 **“找出所有与主角有三度以内关系、且在后期剧情中发生立场转变的人物”**，或 **“追踪某条伏笔线索从埋设到回收的完整链条”**。每个实体作为独立节点存在，拥有类型化的属性集合；实体间

的关系则明确标注语义类型，使离散的信息转化为可计算的网络。这种表示方式不仅便于机器处理，也为人类编剧提供了清晰的全局视图——通过可视化界面，可以直观把握人物关系网络的密度分布、情节发展的节奏曲线、以及世界设定的完整度。

1.2.3 支持动态检索，为生成任务提供精准上下文 RAG（Retrieval-Augmented Generation）架构将知识图谱的检索能力与 LLM 的生成能力有机结合。改编任务启动时，系统首先解析待改编文本的内容特征，识别其中涉及的实体集合；继而以这些实体为起点，在图谱中进行**多跳关系遍历**，检索相关的背景信息；最后将检索结果转化为自然语言描述，与原始文本共同构成增强后的提示。这种"检索-组装-生成"的流程确保模型始终获得最相关的上下文，而非被无关信息淹没。检索策略可灵活配置：处理人物对话场景时，优先检索人物关系子图和近期互动历史；处理动作场景时，优先检索地点设定和相关道具信息；处理情感高潮时，优先检索人物的心理发展轨迹和情感铺垫事件。

1.2.4 实现跨章节的逻辑一致性校验 知识图谱的显式结构使自动化一致性校验成为可能。系统可定义一系列图谱约束规则，如**"人物死亡后不应再出场""修仙境界必须遵循练气 → 筑基 → 金丹的递进顺序"**。在改编生成后，系统可将输出结果反向映射为图谱操作，并验证这些操作是否违反既定约束。若检测到冲突，可触发修复流程：或调整生成参数重新生成，或标记人工复核，或在提示中显式加入冲突警告信息。这种**"生成-验证-修复"的闭环**显著提升了改编质量的可靠性，降低了人工后期修正的工作量。

2. 系统总体架构设计

2.1 分层架构概览

层级	核心职责	关键技术组件
数据层	原始小说存储、编码检测、章节分割、文本清洗	流式文件读取、正则表达式分割、chardet 编码检测
知识层	知识图谱构建、实体消歧、关系抽取、版本管理	Neo4j 图数据库、LLM Graph Builder、Cypher 查询引擎
智能层	RAG 检索编排、提示工程、LLM 调用管理、质量评估	LangChain/LlamaIndex、多模型路由、自适应检索策略
应用层	用户交互、剧本编辑、格式导出、协作支持	Streamlit/Gradio 快速原型、Final Draft 格式转换器

2.1.1 数据层：原始小说存储与预处理 数据层负责 300 万字原始小说的可靠存储与初步加工。考虑到文本规模，采用**分块存储策略**：将小说按章节或固定字数（如每 10 万字）切分为独立文件，建立层次化的文件命名规范。预处理流水线包括：**编码检测与统一**（处理 GBK/UTF-8/BOM 等变体）、**异常字符清洗**（去除乱码、控制字符、广告插入）、**结构标记识别**（章节标题、卷次划分、时间/地点标注）。预处理后的章节数据保存为元数据丰富的对象，包括序号、标题、字数、起始位置、涉及人物预估等，为后续的知识抽取提供标准化输入。

2.1.2 知识层：知识图谱构建与维护 知识层是系统的核心记忆中枢，承担小说语义的形式化编码任务。构建流程分为**批量初始化与增量更新**两个阶段：初始化阶段对全本小说进行逐章处理，识别实体、抽取关系、消歧融合，最终导入图库；更新阶段支持单章或片段的追加处理，自动检测新实体、新关系，并处理与已有知识的冲突。知识层还需提供**可视化接口**，将抽象的图谱转化为可交互的网络图，辅助人工审核与创意探索。

2.1.3 智能层：LLM 编排与 RAG 增强生成 智能层负责协调多个 LLM 调用，完成从理解到生成的复杂任务链。关键设计是 **RAG 检索链的精细化实现**——不仅支持基于关键词的精确匹配，更需实现基于语义向量的相似度检索，以及基

于图结构的关联遍历。该层还需管理 LLM 的调用成本与稳定性：实施响应缓存避免重复计算、设计降级策略应对 API 限流、实现重试与错误恢复机制。对于 300 万字的处理规模，批处理与异步队列的设计尤为关键。

2.1.4 应用层：剧本生成、编辑与导出 应用层面向终端用户，提供完整的改编工作流支持。核心功能包括：**改编任务配置**（选择目标格式、集数/时长、风格倾向）、**分段改编执行**（支持批量生成与单章精修）、**人机协作编辑**（可视化对比原文与剧本、支持段落级修改与批注）、**质量评估面板**（一致性评分、情节覆盖率统计、人物出场追踪）、**多格式导出**（Final Draft、Fade In、中文电视剧本格式）。界面设计需兼顾专业编剧的工作习惯与 AI 工具的效率优势，强调**"AI 辅助、人工作决策"**的协作范式。

2.2 技术栈选型

2.2.1 知识图谱存储：Neo4j 图数据库 Neo4j 是当前最成熟的原生图数据库，其原生图存储引擎对关系遍历查询具有显著性能优势。社区版已足以支撑**百万级节点、千万级关系**的规模，企业版则提供高可用集群与高级安全特性。Cypher 查询语言直观表达图模式匹配，如`(p:Person)-[:LOVES]->(q:Person)<-[:HATES]-(r:Person)`可简洁描述复杂的人物关系网络。对于小说改编场景，APOC 扩展库提供丰富的图算法支持（社区发现、路径分析、相似度计算），可用于识别核心人物圈、发现情节主线、检测叙事断裂。

2.2.2 LLM 编排框架：LangChain/LlamaIndex LangChain 是当前最流行的 LLM 应用开发框架，其模块化设计完美适配小说改编的复杂流程。特别值得关注的是 **LLM Graph Builder 工具**——该工具可直接将文本批量转换为知识图谱，大幅降低工程实现成本。LlamaIndex 作为替代方案，在检索增强方面有其特色，两者可根据具体需求选择或组合使用。

2.2.3 向量检索：Milvus/Pinecone（可选补充） 虽然知识图谱提供了结构化的关系检索，但在某些场景下补充向量语义检索可提升召回质量。例如，当改编任务涉及**"寻找与当前场景情感基调相似的前序场景"**时，基于向量相似度的检索比图遍历更为直接。推荐采用**"混合检索"策略**：以图谱检索为主确保结构化信息的完整覆盖，以向量检索为辅捕捉语义层面的隐含关联。

2.2.4 核心模型：GPT-4/Claude/国产大模型

模型	上下文窗口	核心优势	适用场景	成本估算（300 万字）
GPT-4 Turbo	128K tokens	复杂推理、创意写作、指令遵循	关键场景精修、质量把关	$500-2000
Claude 3 Opus	200K tokens	长文本理解、文学风格、安全性	长章节批量处理、主题分析	$400-1500
文心一言/通义千问	32K-128K tokens	中文优化、合规可控、成本低廉	MVP 验证、大规模预处理、日常任务	¥200-800

推荐采用**"模型路由"策略**：关键创作环节使用最强模型（GPT-4/Claude-3-Opus），辅助任务使用性价比模型，通过路由机制动态分配。

2.2.5 开发语言：Python 3.10+ Python 是 LLM 应用开发的事实标准语言。关键依赖库包括：LangChain/LlamaIndex（编排框架）、neo4j-python-driver（图数据库连接）、transformers/tokenizers（本地模型支持）、gradio/streamlit（快速原型界面）、pydantic（数据验证）、asyncio（异步并发）。Python 3.10+ 的模式匹配、更精确的类型提示等特性，可提升大型应用的可维护性。

3. 知识图谱构建模块

3.1 小说内容结构化解析

3.1.1 章节级文本切分（基于正则表达式识别”第 X 章”等模式） 章节是小说叙事的基本单元，也是知识抽取与改编生成的处理粒度。自动章节分割需处理多种标题格式：

格式类型	示例	正则模式
中文数字	“第一章”、“第壹章”	`r'第[一二三四五六七八九十百千万]+章'`
阿拉伯数字	“第 1 章”、“第 01 章”	`r'第\d+章'`
混合形式	“第一卷第三章”	级联匹配：卷模式 + 章模式
特殊标记	“楔子”、“尾声”、“番外”	关键词列表匹配

分割流程：读取完整文本 → 正则匹配所有章节标题位置 → 按位置切分文本 → 为每章生成独立文件。对于 300 万字小说，预计产生 **100-300 个章节文件**，需建立章节元数据索引支持快速定位与批量处理。开源工具 Python-Novel-Chapter-Splitter 提供了经过验证的实现基础，工业化部署需增强批量处理、编码鲁棒性、分割质量评估、断点续传等能力。

3.1.2 场景级细粒度分割（识别时间、地点转换标志） 剧本改编需要比章节更细的粒度——**场景（Scene）**，即同一时间和地点内的连续动作。分割依据包括：

标志类型	典型表达	处理策略
时间转换	“三天后”、“翌日”、“十年后”	规则匹配 + 时间表达式解析
地点转换	“回到京城”、“踏入大殿”	地点名词识别 + 介词模式
视角转换	POV 人物切换	人物出场频率变化检测
叙事节奏	空行、段落长度突变	启发式规则 + 模型分类

场景分割的结果需标注：时间属性（绝对/相对/模糊）、地点属性（空间层级、场景功能）、人物在场集合、场景类型（对话/动作/描写/心理主导）。这些标注为后续的剧本格式转换奠定基础。

3.1.3 文本清洗与编码统一（处理 GBK/UTF-8 等格式） 原始小说文本常包含多种噪声，需系统清洗：

噪声类型	处理方式	注意事项
编码混乱	chardet 自动检测 → UTF-8 统一转换	保留原始备份，记录转换日志
HTML/XML 标签	正则去除或解析提取	保留有意义的结构标记
广告/评论插入	模式库匹配删除	人工审核边界案例

噪声类型	处理方式	注意事项
OCR 识别错误	语言模型置信度检测	标记待复核，避免过度”修正”
特殊排版符号	规范化或保留语义	如*强调*可转化为 Markdown

清洗过程必须**可逆和可审计**，支持回溯到任意中间状态。

3.2 实体抽取与关系构建

3.2.1 核心实体类型定义

3.2.1.1 人物实体（姓名、身份、性格特征、成长弧线） 人物是小说的核心，其图谱表示需支持多维度的动态追踪：

属性层级	具体内容	应用场景
基础属性	姓名（含别名列表）、性别、年龄、外貌标签	角色识别、场景配置
社会属性	职业、地位、所属组织、人际关系网络	冲突设计、群体场景
心理属性	性格维度（大五人格/自定义标签）、核心欲望、深层恐惧	动机推理、对白生成
发展属性	成长弧线类型、关键转变节点、当前状态快照	跨章节一致性校验

人物快照机制是改编质量的关键——在任意时间节点记录人物的完整状态（位置、健康、情绪、能力、关系），支持查询”某角色在第 X 章时的准确状态”，避免”穿越式”错误。

3.2.1.2 地点实体（地理空间、场景功能、象征意义）

维度	属性示例	改编应用
地理层级	世界 → 大陆 → 国家 → 城市 → 建筑 → 房间	场景选择、视觉规模控制
物理特征	气候、地形、建筑布局、装饰风格	环境描写、氛围营造
场景功能	公共空间/私人空间、安全区/危险区、日常/仪式	情节适配、冲突设计
象征意义	主题关联（如”废墟 = 衰败”、“高塔 = 权力”）	视觉隐喻、主题强化

地点实体通过PART_OF关系构建空间树，支持范围查询（“某城市内发生的所有事件”）和路径规划（“从 A 到 B 的移动路线”）。

3.2.1.3 组织实体（家族、门派、势力阵营） 组织是人物的社会归属和冲突的重要载体。关键属性包括：组织类型（家族/门派/国家/商会/秘密结社）、权力结构（层级制/扁平制/网络制）、意识形态/核心价值观、资源基础（经济/武力/知识/信仰）。组织间的关系（同盟、敌对、从属、竞争）构成宏观冲突格局，其网络分析可识别势力集团、预测联盟演变。

3.2.1.4 事件实体（关键情节、转折点、伏笔回收） 事件是叙事的基本单元，其结构化表示支撑情节分析与改编规划：

属性类别	具体内容	查询支持
时间属性	绝对时间、相对顺序、持续时间、与关键时间点的距离	时间线构建、节奏分析
空间属性	发生地点、涉及范围、移动轨迹	空间叙事、场景调度
参与属性	主动方、被动方、旁观者、各角色功能	人物出场优化、视角选择
叙事属性	事件类型、冲突强度、情感基调、叙事功能	情节单元识别、高潮定位
因果属性	直接原因、必要条件、连锁后果	逻辑校验、压缩影响评估

伏笔-回收关系的显式标注是改编质量的关键——系统需确保每个伏笔在适当场景得到回应，避免遗漏或过早揭露。

3.2.1.5 物品实体（道具、武器、信物等麦高芬元素） 物品在叙事中常承担超越物理功能的符号作用：

功能类型	典型示例	追踪要点
麦高芬（情节引擎）	需要争夺的宝藏、待解的谜题	所有权流转、各方动机
能力载体	武器、功法、魔法物品	能力规格、使用限制、副作用
情感寄托	定情信物、家族遗物	与人物的情感纽带、象征意义
信息载体	密信、地图、传承记忆	信息内容、知情者范围、揭露时机

3.2.2 关系类型体系

关系类别	具体类型	属性标注
人物关系	血缘、婚姻、师徒、爱恋、仇恨、嫉妒、同盟、竞争、背叛	起始时间、结束时间、强度、公开度、动态性

关系类别	具体类型	属性标注
时空关系	BEFORE/AFTER/SIMULTANEOUS/DURING（时间）；PART_OF/ADJACENT_TO/CONNECTED_BY（空间）	时间跨度、距离度量、路径成本
因果关联	CAUSES（充分/必要/促成）、MOTIVATES、ENABLES/HINDERS、LEADS_TO	因果强度、条件类型、连锁深度
主题关联	SYMBOLIZES（象征）、REPRESENTS（代表）、ECHOES（呼应）、PARALLELS（平行）	主题层次、变奏方式、情感共鸣

3.2.3 动态知识图谱更新机制

机制	功能描述	实现要点
增量式章节处理	新章节进入时，局部抽取并融合到现有图谱	实体链接优先匹配已有节点，降低消歧难度
实体消歧	识别同一实体的多种指代表达	规则匹配 + 上下文相似度 + 图谱结构约束
关系冲突检测	识别并标记矛盾的关系断言	时间一致性、属性范围、互斥规则
版本控制	追踪图谱演变，支持回溯与对比	时间戳标记、变更日志、快照备份

3.3 知识图谱质量保障

图谱构建的准确性直接影响改编质量。推荐采用**“自动抽取 + 人工审核”的混合模式**：LLM 完成大规模批量抽取，人工聚焦关键实体（主角、核心反派、重要道具）和复杂关系（多角关系、身份伪装、时间循环）的校验。质量评估指标包括：实体覆盖率（人工抽样评估）、关系准确率（抽样验证）、图谱连通性（核心人物/事件的关联密度）、叙事结构可识别性（能否从图谱还原主线脉络）。

4. 上下文管理与 RAG 增强生成

4.1 双层记忆架构设计

记忆层级	存储形式	内容特征	访问方式
长期记忆	Neo4j 知识图谱	完整世界观、人物全档案、事件全历史、主题网络	结构化查询（Cypher）、多跳遍历
短期记忆	LLM 上下文窗口	当前处理章节的原文、相邻章节摘要、已生成片段	直接嵌入提示
工作记忆	动态检索子图	与当前任务高度相关的实体、关系、事件摘要	RAG 检索 → 文本化组装

工作记忆是连接长期记忆与生成任务的关键桥梁——根据当前改编需求，从图谱中检索最相关的子网络，转化为自然语言描述后注入提示。其容量受限于 LLM 的剩余上下文空间，需精心设计检索策略以最大化信息价值。

4.2 检索增强生成（RAG）流程

```
改编任务输入
    ↓
查询理解（识别实体、推断信息需求类型）
    ↓
图谱检索（实体链接 → 关系遍历 → 子图提取 → 相关性排序）
    ↓
上下文组装（节点描述 + 关系陈述 + 事件摘要 + 主题关联）
    ↓
提示构建（系统指令 + 世界观注入 + 人物状态 + 改编约束 + 原文片段）
    ↓
LLM生成 → 输出解析 → 格式转换 → 一致性校验
```

检索策略的差异化配置:

改编场景	检索重点	遍历深度
人物对话戏	人物关系网络、近期互动历史、情感状态变化	2-3 跳
动作场面	地点设定、能力参数、道具功能、战斗规则	1-2 跳
情感高潮	人物心理弧线、情感铺垫事件、主题关联	2-4 跳
世界观揭示	宏观设定、历史背景、规则约束、象征系统	1-2 跳

4.3 自适应上下文窗口策略

策略	功能描述	实现机制
分层摘要机制	章节摘要（200-500 字）→ 卷摘要（1000-2000 字）→ 全书摘要（3000-5000 字）	LLM 自动生成 + 人工校验，建立多级索引
关键情节锚点	标记转折点、高潮、伏笔回收等叙事路标	自动识别（事件重要性评分）+ 人工标注
人物出场追踪	维护每个人物的动态状态向量	每次出场后更新，新场景前检索校验

5. 剧本改编生成引擎

5.1 电视剧与电影剧本差异处理

维度	电视剧改编	电影改编
结构单元	20-40 集 × 45 分钟，每集独立闭环 + 跨集悬念	90-150 分钟，三幕结构，高度紧凑
节奏控制	允许较慢铺垫，每集 2-3 个情感/情节起伏	每分钟必须有推进，拒绝冗余
信息密度	可保留多条支线，人物关系网络复杂	大幅压缩支线，合并人物，聚焦核心冲突
悬念设计	集末钩子（cliffhanger）驱动连续观看	幕间转折维持张力，结局必须有力
改编策略	按集规划，识别自然分集边界，优化钩子位置	激进压缩，识别”不可删除”关键路径，强化视觉动作

三幕结构的关键节点（电影）：

- **情节点 I**（约 15 分钟）：打破平衡的事件，主角踏上旅程
- **中点**（约 60 分钟）：虚假胜利或重大揭示，方向转折
- **情节点 II**（约 75 分钟）：最低谷后的觉醒，汇聚力量
- **高潮**（约 90-120 分钟）：最终对抗，核心冲突解决

5.2 分段改编策略

粒度级别	适用场景	优势	风险
场景级	关键情节精细打磨	保留最多细节，节奏控制精准	成本高，上下文碎片化
章节级	常规内容批量处理	平衡效率与质量，利用作者原生单元	可能丢失跨章节关联
事件级	宏观结构把握，复杂交织情节	捕捉完整因果链，主题一致性强	可能过度压缩细腻描写

推荐策略：初稿采用章节级快速生成，精修阶段下沉至场景级局部优化，关键情节（高潮、转折）采用事件级多方案探索。

5.3 生成提示模板设计

模板模块	核心内容	信息来源
世界观注入	时代背景、核心规则、势力分布、当前局势	图谱宏观节点 + 地点/组织实体
人物状态	位置、身体/情绪状态、短期目标、核心矛盾、关键关系	人物实体动态属性 + 关系边
改编约束	目标格式、时长/场景数、对白比例、视觉动作要求	用户配置 + 平台规范
风格指导	原著基调、目标受众、改编风格、参考作品	文本分析 + 用户指定

6. 开发实现步骤

6.1 环境准备与依赖安装

组件	部署方式	关键配置
Neo4j	Docker: `docker run -p 7474:7474 -p 7687:7687 neo4j:latest`	内存 4GB，设置初始密码，启用 APOC 扩展
Python 环境	3.10+，poetry/conda 管理	`pip install langchain langchain-neo4j neo4j-python-driver openai`

组件	部署方式	关键配置
LLM API	多密钥配置，速率限制管理	Token Bucket 限流，成本监控，降级策略

6.2 数据预处理流水线

步骤	技术实现	输出
文件读取与编码检测	chardet + 流式读取	UTF-8 编码的文本流
章节分割	多层正则 + 异常处理	章节对象列表（含元数据）
元数据提取	NER + 规则匹配	时间标记、地点标记、人物出场预估

6.3 知识图谱构建实现

步骤	关键操作	质量保障
Schema 定义	创建约束与索引（唯一性、存在性）	文档化本体设计，版本管理
LLM Graph Builder 配置	选择工具模式/提示模式，自定义实体/关系类型	小规模测试，准确率验证
批量章节处理	异步并发，错误恢复，进度监控	抽样人工审核，指标追踪
图谱导入	UNWIND 批量操作，事务管理	导入后验证，可视化检查

6.4 改编生成系统开发

组件	技术方案	关键设计
RAG 检索链	LangChain GraphCypherQAChain + 自定义检索器	查询解析，多跳遍历，结果排序
剧本格式转换器	内部 JSON → Fountain/FDX/PDF	分页控制，场景编号，角色名统一
人机协作界面	Streamlit/Gradio 快速原型	原文-剧本对照，版本对比，实时编辑

6.5 测试验证与迭代优化

评估层级	指标	方法
单章节改编	一致性、完整性、可读性、格式合规	自动规则检查 + 人工抽样评分
跨章节连贯性	人物发展、情节呼应、时间线一致性	状态追踪验证，因果链检测
专业反馈	创意性、实用性、修改工作量	编剧试用，结构化访谈，A/B 测试

7. MVP 快速启动方案

7.1 功能边界与阶段规划

阶段	周期	核心交付	里程碑
第一阶段	2 周	章节分割 + 基础图谱构建 + 可视化	成功处理 3-5 本测试小说，图谱准确率 >80%
第二阶段	2 周	RAG 检索链 + 单章节改编 + 基础界面	单章节改编通过质量评估，格式合规率 >95%
第三阶段	2 周	连贯性优化 + 完整工作流 + 导出功能	端到端改编流程跑通，获得专业编剧正面反馈

7.2 成本控制策略

策略	具体措施	预期效果
缓存优化	重复查询结果缓存（Redis/Memcached）	减少 30-50% API 调用
批处理	章节打包处理，异步队列削峰	提升吞吐量，降低单位成本
模型降级	简单任务用 GPT-3.5/国产模型，关键任务用 GPT-4	成本降低 60-80%，质量损失可控
本地部署	Llama 3 70B/ChatGLM-6B 处理高并发场景	消除 API 成本，延迟降低

MVP 阶段成本估算（100 万字小说）：

- 图谱构建：$20-40（主要使用经济模型）
- 改编生成：$50-100（混合模型策略）
- 总计：$70-140 或 ¥500-1000（国产模型为主）

8. 扩展与优化方向

8.1 多模态增强

方向	应用场景	技术方案
角色形象生成	前期概念设计、演员选角参考	Stable Diffusion + 人物描述优化 + 一致性保持
场景概念图	美术团队沟通、投资方提案	文本到图像生成，风格迁移
配音与视频预演	节奏验证、早期反馈收集	TTS + 简单动画/分镜合成

8.2 协作与版本管理

- **多编剧协同编辑**：基于 Operational Transform 或 CRDT 的实时协作，冲突检测与合并
- **改编版本对比与回滚**：Git-like 版本控制，可视化差异，一键回退
- **评论批注与修订追踪**：段落级批注，修订历史，审核工作流

8.3 领域适配与微调

适配维度	具体方向	技术路径
类型小说	玄幻/都市/历史/悬疑的专属本体扩展	领域 Schema 设计，类型特定抽取规则
目标平台	网剧/院线/短视频剧/互动剧	格式模板库，节奏参数配置，分支叙事支持
编剧风格	学习特定编剧或经典作品的改编风格	风格样本收集，LoRA 微调，提示优化

核心洞察：300 万字长篇小说的 AI 改编，本质上是**“记忆工程”与”创意工程”的结合**。知识图谱解决了 LLM 的记忆瓶颈，使其能够像人类编剧一样”通读全书”后再进行创作；而 RAG 架构的精细化设计，则确保了检索信息的精准性与生成过程的可控性。这一技术路径已在多个开源项目和工业实践中得到验证，具备明确的落地可行性。成功的关键在于**分层抽象、渐进迭代、人机协作**——从数据预处理到知识构建，从检索优化到生成控制，每个环节都需要工程严谨性与创意敏感度的平衡。